
Neural Networks Backpropagation

Neural Networks



Classification

Classification in NLP

 x_i (Input) : 단어, 문장, 문서


 y_i (label): 감정, named entities 등

예측된 y값 $p(y|x) = \frac{\exp(W_y.x)}{\sum_{c=1}^{C} \exp(W_c.x)}$ (softmax 이용)

Softmax

- 이진 분류를 하는 경우에는 시그모이드 함수를 사용
- 세 개 이상의 class인 경우에는 소프트맥스 함수를 사용해서 0과 1 사이의 값으로 출력하며, 출력값의 총 합이 1이 되도록 한다

$$p_i = rac{e^{z_i}}{\sum_{i=1}^k e^{z_j}} \; extit{for } i=1,2,\dots k$$



예측값과 실제값의 오차를 계산하기 위해 비용 함수로 Cross Entropy 사용

Cross Entropy

$$H(p,q) = -\sum_{c=1}^{C} p(c) \log q(c)$$

(P는 실제 확률 분포, q는 계산된 확률) 이 함수가 비용함수로 적합한 이유?


c가 one-hot vector에서 1을 가진 원소의 인덱스라고 하자 예측된 y값이 정확한 경우에 q(c)는 1이어야 한다. 이를 식에 대입해보면 -1log(1) = 0, 즉 loss 값이 0이 된다.


Cross entropy loss function over full dataset $\{x_i, y_i\}_{i=1}^N$

$$J(\theta) = \frac{1}{N} \sum_{i=1}^{N} -\log \left(\frac{e^{f_{y_i}}}{\sum_{c=1}^{C} e^{f_c}} \right)$$

NN Classifiers


Neural Network Classifiers





Softmax은 linear한 decision boundary를 제공하기 때문에 제한적 Nonlinear decision boundary >> Neural network

Neural Network Classifiers



활성화 함수는 선형함수가 아닌 **비선형 함수**여야 한다

- 선형함수를 사용하게 되면 hidden layer를 계속 쌓더라도 하나의 layer를 사용한 것과 차이 없음 W₁W₂x=Wx
- 신경망이 깊어져도 흥미로운 계산을 할 수 없게 된다!

NLP deep learning

$$\nabla_{\theta} J(\theta) = \begin{bmatrix} \nabla_{W_{\cdot 1}} \\ \vdots \\ \nabla_{W_{\cdot d}} \\ \nabla_{x_{aardvark}} \\ \vdots \\ \nabla_{x_{zebra}} \end{bmatrix}$$

NLP에서는 parameter(w)와 word vector(x)를 같이 학습시킨다

pre-trained word vector

훈련 데이터가 적은 상황에서 이미 훈련되어져 있는 pre-trained word vector를 임베딩 벡터 로 사용하기도 한다

훈련 데이터가 적은 경우 해당 문제에 특화된 임베딩 벡터를 만드는게 쉽지 않음. 따라서 해당 문제에 특화된 것은 아니지만 일 반적이고 많은 훈련데이터로 학습된 임베딩 벡 터를 사용하면 성능을 개선할 수 있다.

Window Classification

NER은 문장 안에서 Location, Person, Organization 등 개체명(Named Entity)를 분류하는 방법론이다. '디카프리오가 나온 영화 틀어줘'라는 문장에서 '디카프리오'를 사람으로 인식하는 것을 목표로 한다.


"First National Bank Donates 2 Vans To Future School of Fort Smith"

NER 힘든 이유

- 1. Entity 경계를 정하기 힘듦. (First National Bank vs. National Bank
- 2. Entity 구분하기 힘듦. (Future school?)
- 3. Unknown entit에 대한 class를 얻기 힘듦.


Input data: 토큰화와 품사 태깅 전처리를 끝내고 난 상태를 입력으로 한다

방법1: window에서 word-vector의 평균 구하기




문제점:각 단어의 위치 정보를 잃어버린다

방법2: 모든 word-vector concatenate 하기



방법2: 모든 word-vector concatenate 하기



이 때 비선형 활성화 함수를 사용해야 단어 간의 비 선형적인 관계를 나타낼 수 있다(interaction term)

예를 들어 첫번째 단어가 museum이고 두번째 단어가 in 이나 or 같은 전치사인 경우에 그 다음 center 단어가 location일 수 있다는 좋은 신호가 된다.

Output s의 경우 확률 값으로 변환을 하거나, 그대로 사용하기도 함

Case 1: 확률 값으로 변환

Output s를 softmax를 사용해서 확률 값으로 변환, cross entropy loss를 사용

$$p(y|\mathbf{S}) = \frac{\exp(\mathbf{S})}{\sum_{c=1}^{C} \exp(\mathbf{S})} = \text{softmax}(\mathbf{S})$$

$$J(\theta) = \frac{1}{N} \sum_{i=1}^{N} - \log p(y|s)$$

Case 2: 그대로 사용(unnormalized scores)

Output s를 그대로, Max-margin loss 사용

 $X_{\text{window}} = [x_{\text{museums}} x_{\text{in}} x_{\text{Paris}} x_{\text{are}} x_{\text{amazing}}]$

가운데 단어가 Location인지 아닌지 분류해보자

Corpus 내 모든 위치에서 학습시키며, negative-sampling 적용함

- True window: museums in Paris are amazing - Corrupt window: Not all museums in Paris Center 단어가 NER location으로 label되지 않은 경우 모두 corrupt window에 해당한다 Min-margin loss

아이디어: true window의 score는 크게 corrupt window의 score는 낮게 나오도록 하자

s = score(museums in Paris are amazing)

 s_c = score(Not all museums in Paris)

minimize $J = \max(1 + s_c - s, 0)$

 $s_c-s>0$ 인 경우 학습이 더 진행되어야 하지만, $s-s_c>0$ 인 경우 true window의 score가 더 크기 때문에 학습 중단

여기서 1은 margin으로 true window와 corrupt window의 구분을 명확히 하기 위함

Matrix Calculus

Jacobian Matrix

$$f(x) = [f_1(x_1 + x_2 + \dots + x_n), \dots, f_m(x_1 + x_2 + \dots + x_n)]$$

Input n개 output m개인 함수에 대한 Jacobian Matrix 편미분으로 구성된 mxn 크기의 matrix


$$\frac{\partial f}{\partial x} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix} , \quad \left(\frac{\partial f}{\partial x}\right)_{ij} = \frac{\partial f_i}{\partial x_j}$$

연산에서 사용할 유용한 Jacobians

1.
$$\frac{\partial}{\partial x}(Wx + b) = W$$

2. $\frac{\partial}{\partial b}(Wx + b) = I$
3. $\frac{\partial}{\partial u}(u^{T}h) = h^{T}$

계산은 알아서 해보자!



이번에는 W에 관해 미분해보자

$$\frac{\partial s}{\partial \boldsymbol{W}} = \frac{\partial s}{\partial \boldsymbol{h}} \frac{\partial \boldsymbol{h}}{\partial \boldsymbol{z}} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{W}}$$

$$\frac{\partial s}{\partial \boldsymbol{b}} = \frac{\partial s}{\partial \boldsymbol{h}} \frac{\partial \boldsymbol{h}}{\partial \boldsymbol{z}} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{b}}$$

앞부분 연산과정은 동일하다! 중복된 연산을 피할 수 있다

Output shape

$$\frac{\partial s}{\partial w}$$
의 Input nxm개 output 1개 \rightarrow 1xnm matrix??

$$\frac{\partial s}{\partial \boldsymbol{W}} = \frac{\partial s}{\partial \boldsymbol{h}} \frac{\partial \boldsymbol{h}}{\partial \boldsymbol{z}} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{W}} = \boldsymbol{\delta} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{W}}$$

$$\boldsymbol{\delta}$$
: 1xn $\frac{\partial \boldsymbol{z}}{\partial \boldsymbol{W}} = \boldsymbol{x}$: mx1

nxm 사이즈가 나올 수 없 다 파라미터 업데이트를 위해 우리가 원하는 output 사이즈는

$$\begin{bmatrix} \frac{\partial s}{\partial W_{11}} & \dots & \frac{\partial s}{\partial W_{1m}} \\ \vdots & \ddots & \vdots \\ \frac{\partial s}{\partial W_{n1}} & \dots & \frac{\partial s}{\partial W_{nm}} \end{bmatrix}$$

$$\frac{\partial s}{\partial \mathbf{W}} = \boldsymbol{\delta}^T \quad \boldsymbol{x}^T$$
$$[n \times m] \quad [n \times 1][1 \times m]$$

우리가 원하는 형태 nxm matrix를 얻기 위해 행렬 변환을 하자!

Backpropagation

Derivative wrt a weight matrix

- 우리가 계산하고자 하는 것: $\frac{\partial s}{\partial \boldsymbol{W}}$ $s = \boldsymbol{u}^T \boldsymbol{h}$
- chain rule을 사용하자!

$$\frac{\partial s}{\partial \boldsymbol{W}} = \frac{\partial s}{\partial \boldsymbol{h}} \frac{\partial \boldsymbol{h}}{\partial \boldsymbol{z}} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{W}}$$

$$s = u^{T}h$$

$$h = f(z)$$

$$z = Wx + b$$

$$x = [x_{\text{museums}} x_{\text{in}} x_{\text{Paris}} x_{\text{are}} x_{\text{amazing}}]$$

• 앞에서 구한 $\frac{\partial s}{\partial \boldsymbol{W}} = \delta \frac{\partial z}{\partial \boldsymbol{W}}$ 로 다시 표현하면,

$$\frac{\partial s}{\partial W} = \delta \frac{\partial z}{\partial W} = \delta \frac{\partial}{\partial W} W x + b \qquad \delta = \frac{\partial s}{\partial h} \frac{\partial h}{\partial z} = u^T \circ f'(z)$$

Deriving gradients for backprop

• 이제 아래 식을 W_{ij} 에 대해 미분해보자.


$$\frac{\partial s}{\partial \mathbf{W}} = \boldsymbol{\delta} \frac{\partial \mathbf{z}}{\partial \mathbf{W}} = \boldsymbol{\delta} \frac{\partial}{\partial \mathbf{W}} \mathbf{W} \mathbf{x} + \mathbf{b}$$


z = Wx

$$\begin{bmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix}$$

$$z_{1} = \sum_{k=1}^{4} w_{1k} x_{k} \qquad \left[\begin{bmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \end{bmatrix} \begin{bmatrix} x_{1} \\ x_{2} \\ x_{3} \end{bmatrix} = \begin{bmatrix} z_{1} \\ z_{2} \end{bmatrix}$$

$$\begin{bmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix}$$







Deriving gradients for backprop

$$\frac{\partial z_1}{\partial w_{1j}} = \frac{\partial \sum_{k=1}^4 w_{1k} x_k}{\partial w_{1j}} = x_j$$

 W_{ij} Only contributes to zi

$$\frac{\partial z_i}{\partial w_{ij}} = \frac{\partial \sum_{k=1}^4 w_{ik} x_k}{\partial w_{ij}} = x_j$$





Deriving gradients for backprop

• 그러므로, s를 W_{ii} 에 대해서 미분하면

$$\frac{\partial s}{\partial \boldsymbol{W}} = \begin{bmatrix} \frac{\partial s}{\partial \boldsymbol{h}} \frac{\partial \boldsymbol{h}}{\partial \boldsymbol{z}} & \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{W}} \\ \boldsymbol{\delta} & = \begin{bmatrix} \delta_1 \\ \delta_2 \end{bmatrix}$$

$$\frac{\partial s}{\partial W_{ij}} = \delta_i x_j$$
Error signal Local gradient from above signal

- 그런데 우리는 모든 W 대한 gradient를 구하고 싶다.
- Overall answer: Outer product


$$egin{array}{ll} rac{\partial s}{\partial oldsymbol{W}} &= & oldsymbol{\delta}^T & oldsymbol{x}^T \ [n imes n] &= [n imes 1][1 imes m] \end{array}$$

Deriving gradients wrt words for window model 단어 벡터에 도달하고 단어를 업데이트하는 gradient는 각 단어

벡터에 대해 간단히 분할할 수 있다.


$$\begin{aligned} \nabla_x J &= W^T \delta = \delta_{x_{window}} \\ \mathbf{x}_{\text{window}} &= [\mathbf{x}_{\text{museums}} \ \mathbf{x}_{\text{in}} \ \mathbf{x}_{\text{Paris}} \ \mathbf{x}_{\text{are}} \ \mathbf{x}_{\text{amazing}}] \end{aligned}$$

$$\delta_{window} = \begin{bmatrix} \nabla_{x_{museums}} \\ \nabla_{x_{in}} \\ \nabla_{x_{Paris}} \\ \nabla_{x_{are}} \\ \nabla_{x_{amazing}} \end{bmatrix} \in \mathbb{R}^{5d}$$



A pitfall when retraining word vectors

: single word를 사용하여 영화 감상평에 대한 로지스틱 회귀분 류를 훈련하고 있다고 하자.




- In the training data: "TV"와 "Telly"가 존재
- In the testing data: "television"만 존재
- pretrained word vector에 세 단어가 비슷한 위치에 존재 :

Question: word vectors들을 업데이트 하면 어떤 일이 일어날까?

A pitfall when retraining word vectors

: single word를 사용하여 영화 감상평에 대한 로지스틱 회귀분 류를 훈련하고 있다고 하자.



Training set으로 모델을 학습하면 - "TV"와 "telly"는 gradient를 받아 업데이트

Test set에만 있는 "television"은 업데이트되지 않음

So what should we do?


"pre-trained" word vectors를 사용해야 할까?

- Almost always, yes!
- pre-trained data는 방대한 양에 대해 사람들이 이미 학습을 시켰다
- 따라서 TV, telly, television처럼 train set포함의 유무와 관계 없이 어느 정도 단어간 관계가 형성된다.
- 그러나 데이터가 매우 많다면(100s millions of words of data) 처음부터 학습을 시켜도 무관


Fine-tune을 해야할까?

- 만약 적은 train set(100,000개 미만)을 갖고 있다면 fine-tuning하지 말 것
- 많은 train set(100만 개 이상)을 갖고 있다면 fine-tune을 하는게 성능 향상에 도움이 된다.

Forward propagation



Back propagation




$$s = \boldsymbol{u}^T \boldsymbol{h}$$

 $\boldsymbol{h} = f(\boldsymbol{z})$
 $\boldsymbol{z} = \boldsymbol{W} \boldsymbol{x} + \boldsymbol{b}$
 \boldsymbol{x} (input)

Single Node – scalar function example


- 노드가 "upstream gradient"를 받는다.
- 목표는 올바른 "downstream gradient" 을 전달하는 것이다. 각 노드는 **local gradient** 을 갖고 있다.



Single Node – scalar function example


chain rule

[downstream gradient] = [upstream gradient] x [local gradient]



Single Node: Multiple Input -Matrix-Vector example

$$\boldsymbol{z} = \boldsymbol{W} \boldsymbol{x} \begin{bmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix} \begin{bmatrix} \frac{\partial s}{\partial \boldsymbol{W}} = \frac{\partial s}{\partial \boldsymbol{z}} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{W}} = \boldsymbol{\delta} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{W}} = \boldsymbol{\delta} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{w}} \\ \frac{\partial s}{\partial \boldsymbol{z}} = \boldsymbol{\Sigma}^2 + \boldsymbol{\delta} \frac{\partial z}{\partial \boldsymbol{w}} \end{bmatrix}$$



$$\frac{\partial s}{\partial \boldsymbol{W}} = \frac{\partial s}{\partial \boldsymbol{z}} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{W}} = \boldsymbol{\delta} \frac{\partial \boldsymbol{z}}{\partial \boldsymbol{W}}$$

$$\frac{\partial s}{\partial w_{ij}} = \sum_{k=1}^{2} \delta_k \frac{\partial z_k}{\partial w_{ij}} = \delta_i x_j$$

$$\frac{\partial s}{\partial \boldsymbol{W}} = \boldsymbol{\delta} \cdot \boldsymbol{x}^T = \begin{bmatrix} \delta_1 \\ \delta_2 \end{bmatrix} \begin{bmatrix} x_1 & x_2 & x_3 & x_4 \end{bmatrix}$$

$$\frac{\partial s}{\partial x} = \frac{\partial s}{\partial z} \frac{\partial z}{\partial x} = \delta \frac{\partial z}{\partial x}$$

$$= \begin{bmatrix} \delta_1 \\ \delta_2 \end{bmatrix} \qquad \frac{\partial s}{\partial x_j} = \sum_{k=1}^2 \delta_k \frac{\partial z_k}{\partial x_j} = \delta_1 w_{1j} + \delta_2 w_{2j}$$

$$\frac{\partial s}{\partial x} = \mathbf{W}^T \cdot \mathbf{\delta} = \begin{bmatrix} w_{11} & w_{21} \\ w_{12} & w_{22} \\ w_{13} & w_{23} \\ w_{14} & w_{24} \end{bmatrix} \begin{bmatrix} \delta_1 \\ \delta_2 \end{bmatrix}$$

An Example


$$f(x, y, z) = (x + y) \max(y, z)$$
$$x = 1, y = 2, z = 0$$

$$a = x + y$$

$$b = \max(y, z)$$

$$f = ab$$

Forward prop steps



An Example


$$f(x, y, z) = (x + y) \max(y, z)$$
$$x = 1, y = 2, z = 0$$

$$a = x + y$$

$$b = \max(y, z)$$

$$f = ab$$

Back prop steps



An Example


$$f(x, y, z) = (x + y) \max(y, z)$$
$$x = 1, y = 2, z = 0$$

$$a = x + y$$

$$b = \max(y, z)$$

$$f = ab$$

Back prop steps



An Example


$$f(x, y, z) = (x + y) \max(y, z)$$
$$x = 1, y = 2, z = 0$$


$$a = x + y$$

$$b = \max(y, z)$$

$$f = ab$$


Back prop steps






Gradients sum at outward branches

$$\frac{\partial f}{\partial y} = \frac{\partial f}{\partial a} \frac{\partial a}{\partial y} + \frac{\partial f}{\partial b} \frac{\partial b}{\partial y}$$




Efficiency: compute all gradients at once


Incorrect way of doing backprop:



Correct way:



Back-Prop in General Computation Graph




- 1. Fprop: visit nodes in topological sort order Compute value of node given predecessors
- 2. Bprop:
- initialize output gradient = 1
- visit nodes in reverse order: Compute gradient wrt each node using gradient wrt successors

$$\{y_1, y_2, \dots y_n\}$$
 = successors of x $\frac{\partial z}{\partial x} = \sum_{i=1}^n \frac{\partial z}{\partial y_i} \frac{\partial y_i}{\partial x}$

In general our nets have regular layer-structure and so we can use matrices and Jacobians...


Back-Prop in General Computation Graph



- The gradient computation can be automatically inferred from the symbolic expression of the fprop
- Each node type needs to know how to compute its output and how to compute the gradient wrt its inputs given the gradient wrt its output
- Modern DL frameworks (Tensorflow, PyTorch, etc.) do backpropagation for you but mainly leave layer/node writer to hand-calculate the local derivative

Backprop Implementations


```
class ComputationalGraph(object):
   # . . .
   def forward(inputs):
       # 1. [pass inputs to input gates...]
       # 2. forward the computational graph:
        for gate in self.graph.nodes_topologically_sorted():
            gate.forward()
        return loss # the final gate in the graph outputs the loss
   def backward():
        for gate in reversed(self.graph.nodes topologically sorted()):
            gate.backward() # little piece of backprop (chain rule applied)
        return inputs gradients
```



```
Add의 경우
z = x+y
Max의 경우
z = max(x, y)
```

Backprop Implementations


단순한 layer 구현하기



```
apple = 100
apple_num = 2
tax = 1.1
#계층들
mul_apple_layer = MulLayer()
mul_tax_layer = MulLayer()
# 순전파
apple_price = mul_apple_layer.forward(apple, apple_num)
price = mul tax layer.forward(apple price, tax)
print('%d' % price)
# 역전파
dprice = 1
dapple_price, dtax = mul_tax_layer.backward(dprice)
dapple, dapple_num = mul_apple_layer.backward(dapple_price)
print("%.1f, %d, %d" % (dapple, dapple_num, dtax))
220
2.2, 110, 200
```

Backprop Implementations

단순한 layer 구현하기



```
apple = 100
apple_num = 2
orange = 150
orange_num = 3
tax = 1.1
# 계층들
mul_apple_layer = MulLayer()
mul orange layer = MulLayer()
add apple_orange_layer = AddLayer()
mul_tax_layer = MulLayer()
# 순전파
apple price = mul apple layer.forward(apple, apple num)
orange price = mul_orange_layer.forward(orange, orange_num)
all price = add apple orange layer.forward(apple price, orange price)
price = mul tax layer.forward(all price, tax)
# 역전파
dprice = 1
dall_price, dtax = mul_tax_layer.backward(dprice)
dapple_price, dorange_price = add_apple_orange_layer.backward(dall_price)
dorange, dorange_num = mul_orange_layer.backward(dorange_price)
dapple, dapple_num = mul_apple_layer.backward(dapple_price)
print('%d' % price)
print("%d, %.1f, %d, %d" % (dapple num, dapple, dorange, dorange num, dtax))
715
49500, 990.0, 660.0, 33000, 650
```

Gradient Checking: Numerical Gradient

For small h (
$$\approx$$
 1e-4), $f'(x) \approx \frac{f(x+h) - f(x-h)}{2h}$

- 미분 공식을 통해 gradient를 쉽게 계산 가능
- 적용할 때마다 f를 새롭게 계산해야 하기 때문에 computational graph 방식에 비해 매우 느림
- 따라서 일부에 대해서만 gradient가 제대로 계산되었는지 확인하는 용도


```
Snippet 2.1
def eval_numerical_gradient(f, x):
 a naive implementation of numerical gradient of f at x
 - f should be a function that takes a single argument
 - x is the point (numpy array) to evaluate the gradient
 at
  fx = f(x) # evaluate function value at original point
 grad = np.zeros(x.shape)
 h = 0.00001
 # iterate over all indexes in x
 it = np.nditer(x, flags=['multi_index'],
                  op_flags=['readwrite'])
 while not it.finished:
   # evaluate function at x+h
   ix = it.multi_index
   old_value = x[ix]
   x[ix] = old_value + h # increment by h
   fxh_left = f(x) # evaluate f(x + h)
   x[ix] = old_value - h # decrement by h
   fxh_right = f(x) # evaluate f(x - h)
   x[ix] = old_value # restore to previous value (very
          important!)
   # compute the partial derivative
   grad[ix] = (fxh_left - fxh_right) / (2*h) # the slope
   it.iternext() # step to next dimension
  return grad
```

Regularization

$$J(\theta) = \frac{1}{N} \sum_{i=1}^{N} -\log \left(\frac{e^{f_{y_i}}}{\sum_{c=1}^{C} e^{f_c}} \right) \qquad J(\theta) = \frac{1}{N} \sum_{i=1}^{N} -\log \left(\frac{e^{f_{y_i}}}{\sum_{c=1}^{C} e^{f_c}} \right) + \lambda \sum_{k} \theta_k^2$$

손실 함수를 그냥 쓰면 training set에 과적합 될 수 있다

- 이를 방지하기 위해 실제 full loss function에는 모든 parameter에 대해 Regularization을 한다
- 보통 L2 Regularization을 많이 이용
- feature가 많은 깊은 모델(e.g. deel model)일수록 뛰어난 효과를 보인다




Regularization

L1 Regularization / L2 Regularization


L1 (Manhattan) distance

$$d_1(I_1,I_2) = \sum_p |I_1^p - I_2^p|$$



L2 (Euclidean) distance

$$d_2(I_1,I_2) = \sqrt{\sum_p \left(I_1^p - I_2^p
ight)^2}$$



L1 Regularization

Cost =
$$\sum_{i=0}^{N} (y_i - \sum_{j=0}^{M} x_{ij} W_j)^2 + \lambda \sum_{j=0}^{M} |W_j|$$

L2 Regularization

$$\mathbf{Cost} = \sum_{i=0}^{N} (y_i - \sum_{j=0}^{M} x_{ij} W_j)^2 + \lambda \sum_{j=0}^{M} W_j^2$$

$$\mathbf{Loss \ function}$$
Regularization
Term

Vectorization


- looping over word vectors
- versus
- concatenating them all into one large matrix and then multiplying the softmax weights with that matrix


1000 loops, best of 3: 639 µs per loop 10000 loops, best of 3: 53.8 µs per loop

The (10x) faster method is using a C x N matrix • Always try to use vectors and matrices rather than for loops!

```
from numpy import random
N = 500 # number of windows to classify
d = 300 # dimensionality of each window
C = 5 # number of classes
W = random.rand(C,d)
wordvectors_list = [random.rand(d,1) for i in range(N)]
wordvectors_one_matrix = random.rand(d,N)
%timeit [W.dot(wordvectors_list[i]) for i in range(N)]
%timeit W.dot(wordvectors_one_matrix)
```

Non-linearities: The starting points





tanh is just a rescaled and shifted sigmoid (2 as steep, [-1,1]):

Sigmoid와 tanh는 여전히 많이 쓰이지만 deep한 구조에서는 쓰이지 않음 > why?: vanishing gradient

- Deep network에서는 ReLU (좌)를 항상 첫번째로 고려할 것
- 간단할뿐만 아니라 성능도 좋게 나옴
- Leaky ReLU, Parametric ReLU, GeLU 등 다양한 Variation이 존재

Parameter Initialization

일반적으로 작은 random value로 parameter의 초기값을 줘야함

- ✓ 히든 레이어의 bias term은 0으로 초기값을 줘야함
- ✓ 다른 모든 weight들은 Uniform(-r, r)에서 sampling할 것
- ✓ r은 매우 작거나 매우 크면 안됨

Xavier initialization을 자주 이용하기도 함

✔ previous layer size와 next layer size에 맞게 weight variance를 조절

$$\mathrm{Var}(W_i) = rac{2}{n_{\mathrm{in}} + n_{\mathrm{out}}}$$

Optimizer

보통은 그냥 SGD를 써도 최적화가 잘 된다.

✔ 하지만 더 좋은 값을 얻기 위해서는 learning rate를 반드시 튜닝해야 한다.

복잡한 신경망을 학습할 때는 "adaptive" optimizer가 성능이 좋음

- ✓ Adaptive optimizer는 gradient 정보를 계속 축적하며 이를 통해 gradient를 조절하는 방법이다.
 - Adagrad
 - RMSprop
 - Adam <- A fairly good, safe place to begin in many cases
 - SparseAdam
 - • • •

Learning Rates

- 0.001정도의 일정한 learning rate를 일반적으로 씀 It must be order of magnitude right - try powers of 10
- Too big: model may diverge or not converge
- Too small: your model may not have trained by the deadline
- 학습이 진행될수록 learning rate를 감소시키는게 보통 성능이 뛰어남
- By hand: k epoch마다 반으로 줄이기
- By a formula: k epoch마다 r = lr0e-kt 와 같이 증가시키기
- cyclic learning rate와 같이 fancy한 방법들이 존재